


1. 假设第  $i$  个人在第  $v$  个视图中的脑电图邻接矩阵表示为  $G_i^{(v)}$ ，我们对这一脑电图进行 SDAE 编码：



即把一个图  $G$  变成一个特征向量的表示形式  $R$ 。

2. 然后是提出 representation exclusivity 和 indicator consistency 的概念：
  - a) representation exclusivity 定义为：

$$H(R_i^{(v)}, R_i^{(w)})$$

这个 exclusivity 的定义可以理解成同一个 instance 在不同视图下的特征表示  $R$  应该尽量地不同，这是代表了不同视图下的互补性。因此 representation exclusivity 的目标函数为：

$$\max \sum_i \sum_{v \neq w} H(R_i^{(v)}, R_i^{(w)})$$

- b) 接着是 indicator consistency 的定义：

直观上理解，indicator consistency 就是即使同一个 instance 在不同视图下的特征表示  $R$  是不相同的，但是对于同一个 instance，在不同视图下应该划分到同一个簇中。这里我打算用 K-Means 算法，因此 indicator consistency 的目标函数为：

$$\arg_G \min \sum_v \sum_i \|R_i^{(v)} - GC_i^{(v)}\|_2$$

其中， $G$  为 indicator matrix，注意到对于不同的视图  $v$ ， $G$  都是一样的，对应于前面提出的 indicator consistency 的概念； $C_i^{(v)}$  为第  $v$  个视图下，第  $i$  个 instance 对应的簇的质心。

3. 因此，总的目标函数为：

$$\arg_G \min \left( \sum_v \sum_i \|R_i^{(v)} - GC_i^{(v)}\|_2 - \sum_i \sum_{v \neq w} H(R_i^{(v)}, R_i^{(w)}) \right)$$

然后遇到的问题是：如何通过总的目标函数的求解去同时更新 SDAE 的特征学习？现在有一个想法就是，对于第  $i$  个人在第  $v$  个视图的 SDAE 编码，其误差为：

$$\sum_v \left\| R_i^{(v)} - GC_i^{(v)} \right\|_2 - \sum_{v \neq w} H(R_i^{(v)}, R_i^{(w)})$$

假如采用这种方法，算法流程就是：首先将  $G$  输入到 SDAE 网络中，得到  $R$ ，然后优化一遍总的目标函数，计算当前误差，把误差反馈到 SDAE 网络中更新 SDAE 的参数；上述步骤重复迭代多次，直至算法收敛。但是这里算法的收敛性是一个很大的问题。

另一种想法是：参考王凯师兄的毕业论文，从 SDAE 中学习得到一个  $R$ ，然后对总的目标函数的优化更新得到  $R'$ ，因此我们最终就要使所有人的所有视图的  $R$  和  $R'$  尽量相同，即：

$$\begin{aligned} \arg_G \min \big( & \sum_v \sum_i \left\| R_i^{(v)} - GC_i^{(v)} \right\|_2 - \sum_i \sum_{v \neq w} H(R_i^{(v)}, R_i^{(w)}) + \sum_v \sum_i \left( \left\| R_i^{(v)} - R_i'^{(v)} \right\|_2 \right. \\ & \left. + \left\| W_i^v \right\|_2 + \left\| b_i^v \right\|_2 \right) \big) \end{aligned}$$

我还考虑到一个问题，虽然我的算法的初衷是利用最大化 representation exclusivity 和最小化 indicator consistency 的互相对抗训练来更完整地运用一致性和互补性，可是同一个 instance 不同视图的特征表示的不同，不一定会导致同一个 instance 在不同的视图图中会被划分到不同的簇中，这样的话 exclusivity 就没有很好地体现在目标函数中了。

假如算法模型合理，那么下一个遇到的最大问题就是模型收敛性的分析以及对模型的求解，这个我真的不会了。